RAG Evaluation Dataset v1.0 사용 가이드

1. 개요

`dev_benchmark_v1.0.json`은 팀에서 개발하는 RAG 시스템 및 각 모듈을
동일한 질문 기준으로 검증하고 비교하기 위한 공통 Evaluation Dataset입니다.

개발자마다 서로 다른 질문을 사용했을 때 발생하는 평가 기준의 차이를 줄이기 위해
100개 RFP 문서를 기준으로 고정된 평가 문항을 구성했습니다.

---

2. Dataset 구성

- 대상 RFP 문서: 100개
- 문서당 평가 문항: 3개
- 전체 평가 문항: 300개
- Dataset Version: 1.0
- 상태: Frozen

각 RFP 문서마다 다음 세 가지 유형의 질문이 1개씩 포함되어 있습니다.

① direct_fact

RFP에 명시된 핵심 사실 또는 주요 요구사항을 직접 확인하는 질문입니다.

② numeric_condition

금액, 기간, 수량, 일정, 비율, 성능 기준 등
수치 또는 명확한 조건을 확인하는 질문입니다.

③ multi_section

하나의 근거만 확인하는 것이 아니라,
문서 내 서로 떨어진 둘 이상의 관련 정보를 함께 확인해야 답할 수 있는 질문입니다.

따라서 전체 구성은 다음과 같습니다.

- `direct_fact`: 100문항
- `numeric_condition`: 100문항
- `multi_section`: 100문항

- 총 300문항

---

3. 제공 파일

`dev_benchmark_v1.0.json`

실제 평가에 사용하는 공통 Evaluation Dataset 원본입니다.

질문뿐만 아니라 기준 정답, 정답의 핵심 사실, 원문 근거 등의 평가 정보가
함께 포함되어 있습니다.

본 JSON 파일을 Evaluation Dataset의 정본(Source of Truth)으로 사용합니다.

`evaluation_questions.txt`

300개 평가 질문을 빠르게 확인하거나
개발 중 일부 질문을 직접 테스트할 수 있도록 만든 열람용 파일입니다.

`dev_benchmark_v1.0.json`에서 질문 관련 정보만 추출한 파일이며,
평가 데이터의 정본은 JSON 파일입니다.

JSON과 TXT의 내용이 충돌하는 경우 JSON을 기준으로 합니다.

---

4. JSON 주요 필드

각 평가 문항에는 다음과 같은 정보가 포함되어 있습니다.

- `id`
  - 평가 문항의 고유 ID
- `document_id`
  - 질문이 만들어진 RFP 문서의 ID
- `source_filename`
  - 해당 RFP 원본 파일명
- `project_name`
  - 해당 RFP의 사업명
- `question`
  - RAG에 입력할 평가 질문
- `question_type`
  - 질문 유형

    - `direct_fact`
    - `numeric_condition`
    - `multi_section`
- `answerable`
    - 해당 RFP의 내용을 근거로 답변 가능한 질문인지 여부
- `reference_answer`
    - 평가 시 기준으로 사용할 정답(Gold Answer)
- `atomic_facts`
    - 정답에 포함되어야 할 핵심 사실을 세부 단위로 분리한 정보
- `evidence`
    - 정답을 뒷받침하는 RFP 원문 근거
- `reference_context_ids`
    - Retrieval 평가를 위한 Context/Chunk ID 필드

현재 `reference_context_ids`는 비어 있으며,
향후 실제 RAG의 Chunking/Retrieval 구조와 연결하여 사용할 예정입니다.

---

5. Evidence의 페이지 정보

일부 문항의 `evidence.page` 값은 `null`입니다.

이는 원본 문서에서 텍스트를 추출하는 과정에서
페이지 경계 정보가 보존되지 않은 경우가 있기 때문입니다.

원문 근거 자체는 `evidence.text`에 포함되어 있습니다.

---

6. 사용 방법

개발 중 필요한 평가 질문은
`dev_benchmark_v1.0.json`에서 선택하여 사용할 수 있습니다.

질문만 빠르게 확인하거나 일부 질문을 직접 테스트하려는 경우에는
`evaluation_questions.txt`를 사용할 수 있습니다.

Baseline과 Candidate 등 두 구조의 성능을 직접 비교하는 경우에는
가능한 한 동일한 평가 문항을 사용하여 비교해주세요.

전체 300문항을 반드시 모든 개발 단계에서 실행해야 하는 것은 아닙니다.

모듈별 평가 방법, 평가 문항 Sampling 방식,
Retrieval/Generation 평가 Metric 및 자동화 방식은
공통 Evaluation Pipeline에서 별도로 구성할 예정입니다.

---

7. Dataset 사용 시 주의사항

`dev_benchmark_v1.0.json`은 실험 간 비교 기준을 유지하기 위한
팀 공통 고정 Benchmark입니다.

따라서 다음 항목을 임의로 수정하지 않습니다.

- `question`
- `reference_answer`
- `atomic_facts`
- `evidence`

개별 개발자가 새로운 질문을 v1.0 Dataset에 직접 추가하거나
기존 질문/정답을 수정하지 않습니다.

Dataset에서 오류 또는 수정이 필요한 사항을 발견한 경우
직접 수정하지 않고 Evaluation 담당자에게 공유해주세요.

Dataset 자체의 수정이 필요한 경우 기존 v1.0을 덮어쓰지 않고
별도의 새로운 Version으로 관리합니다.

---

8. 현재 단계

현재 제공되는 v1.0 Dataset은 팀원들이 개발 중인 RAG를
공통 질문 기준으로 검증하는 데 사용할 수 있습니다.

향후 Evaluation Pipeline과 연결하여 다음과 같은 평가를
단계적으로 지원할 예정입니다.

- Retrieval 성능 평가
- Generation 성능 평가
- Baseline / Candidate 비교
- 모듈별 실험 결과 비교
- 비용 및 Latency 비교
- 실패 사례 분석

Evaluation Pipeline 및 RAG Adapter 사용 방법은
구현 완료 후 별도로 공유할 예정입니다.